

Cheatsheet

基础公理、条件概率、随机变量

概率公理与集合运算

概率空间三元组: $(\Omega, \mathcal{F}, P)$

基本公理:

- 非负性: $P(A) \geq 0$
- 规范性: $P(\Omega) = 1$
- 可列可加性: 若 $A_1, A_2, \dots$ 互斥, 则 $P(\cup A_i) = \sum P(A_i)$

常用性质:

- $P(A^c) = 1 - P(A)$
- 容斥原理: $P(A \cup B) = P(A) + P(B) - P(AB)$
- 单调性: 若 $A \subset B$, 则 $P(B - A) = P(B) - P(A)$

条件概率、全概率与贝叶斯

条件概率定义: $P(A | B) = \frac{P(AB)}{P(B)}$

全概率公式: 设 $B_1, B_2, \dots$ 构成样本空间 Ω 的一个划分, 则对任意事件 A :
 $P(A) = \sum_i P(A | B_i)P(B_i)$

贝叶斯公式——逆概率: $P(B_i | A) = \frac{P(A|B_i)P(B_i)}{P(A)} = \frac{P(A|B_i)P(B_i)}{\sum_j P(A|B_j)P(B_j)}$

经典例题: 疾病检测:

已知:

- 先验概率: $P(D) = 0.02$ (患病率)
- 敏感性: $P(T | D) = 0.95$ (有病检测出阳性)
- 特异性: $P(T^c | D^c) = 0.98 \Rightarrow P(T | D^c) = 0.02$ (误诊率)

问题: 检测为阳性 T , 实际患病的概率 $P(D | T)$ 是多少?

解题步骤:

- 用全概率公式求分母 $P(T) = P(T | D)P(D) + P(T | D^c)P(D^c)$
- 求贝叶斯公式的分子 $P(T | D)P(D)$
- 贝叶斯公式: $P(D | T) = \frac{P(T|D)P(D)}{P(T)}$

最终求解发现即使检测为阳性, 实际患病概率不到50%, 反直觉。

独立性

事件独立性定义: $A \perp B \iff P(AB) = P(A)P(B)$

条件独立性: $A \perp B | C \iff P(AB | C) = P(A | C)P(B | C)$ 注意: A, B 独立不代表在 C 发生的条件下也独立, 反之亦然。

三个事件相互独立：需要同时满足两两独立(3个等式)且 $P(ABC) = P(A)P(B)P(C)$ 注意：即使 $P(ABC) = P(A)P(BC)$ 且 $P(AB) = P(A)P(B)$ ，也不能推出三者相互独立，更不能推出 $P(ABC) = P(A)P(B)P(C)$ 。

随机变量

累积分布函数(CDF): $F_X(x) = P(X \leq x)$

性质:

- 单调不减: $x_1 < x_2 \Rightarrow F(x_1) \leq F(x_2)$
- 右连续: $\lim_{y \rightarrow x^+} F(y) = F(x)$
- 两个极限: $\lim_{x \rightarrow -\infty} F(x) = 0$ 和 $\lim_{x \rightarrow \infty} F(x) = 1$

离散型变量:

- PMF: $p_X(k) = P(X = k)$
- CDF与PMF的关系: $F(x) = \sum_{x \leq k} p_X(k)$

连续性变量:

- PDF: $f_X(x) = \frac{P(x \leq X \leq x+dx)}{dx}$
- PDF与CDF的关系: $F(X) = \int_{-\infty}^x f(t)dt$, $P(a < X \leq b) = F(b) - F(a)$

经典例题：混合型随机变量的CDF

场景：投硬币觉醒坐火车还是汽车：硬币正面则火车，到达时间 $X \sim \mathcal{U}(20, 25)$ ；硬币反面则汽车，到达时间 $X \sim \mathcal{U}(15, 30)$ 。求 X 的CDF $F_X(x)$

$$F_X(x) = 0.5 \cdot F_{\text{Train}}(x) + 0.5 \cdot F_{\text{Car}}(x)$$

问：CDF总是连续吗？不一定。这里 $F_X(x)$ 是一条连续的曲线，因为两个均匀分布覆盖了区间，且概率权重平滑过渡，但是如果一种情况是离散的点质量，CDF会出现阶梯。

常用分布

常用离散分布

分布名称	符号	PMF $P(X = k)$	期望 $\mathbb{E}[X]$	方差 $\text{Var}(X)$	备注
伯努利	$\text{Ber}(p)$	$p^k(1-p)^{1-k}$	p	$p(1-p)$	一次实验，成功为1
二项	$\text{Bin}(n, p)$	$\binom{n}{k} p^k (1-p)^{n-k}$	np	$np(1-p)$	n 次独立Ber实验成功次数
几何	$\text{Geo}(p)$	$(1-p)^{k-1} p$	$\frac{1}{p}$	$\frac{1-p}{p^2}$	第1次成功所需试验次数
负二项	$\text{NB}(r, p)$	$\binom{k-1}{r-1} p^r (1-p)^{k-r}$	$\frac{r}{p}$	$\frac{r(1-p)}{p^2}$	第 r 次成功所需试验次数
泊松	$\text{Poi}(\lambda)$	$\frac{\lambda^k e^{-\lambda}}{k!}$	λ	λ	稀有事件计数

几何分布的无记忆性: $P(X > m + n \mid X > m) = P(X > n)$ 。这意味着“如果你已经失败了 m 次，再失败 n 次的概率就像重新开始一样”。指数分布也有这个性质。

泊松近似: 当 $n \rightarrow \infty$, $p \rightarrow 0$, $np = \lambda$ 时，二项分布可以用泊松分布近似。

常用连续分布

分布名称	符号	PDF $f_X(x)$	期望 $\mathbb{E}[X]$	方差 $\text{Var}(X)$	备注
均匀	$\mathcal{U}(a, b)$	$\frac{1}{b-a}$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$	概率在区间内平均分布
指数	$\text{Exp}(\lambda)$	$\lambda e^{-\lambda x}$	$\frac{1}{\lambda}$	$\frac{1}{\lambda^2}$	等待时间模型
正态	$\mathcal{N}(\mu, \sigma^2)$	$\frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$	μ	σ^2	中心极限定理的基础；标准化 $Z = \frac{x-\mu}{\sigma}$

如果随机变量 T 有恒定的失效率 $h(t) = \lambda$ ，则 T 必定服从指数分布。 $P(T > t) = e^{-\lambda t}$

泊松过程

记 N_t 为 $[0, t]$ 时间内的到达数，速率为 λ 。

- 计数分布： $N_t \sim \text{Poi}(\lambda t)$
- 间隔时间：到达之间的时间间隔 $T_1, T_2, \dots$ 是i.i.d的 $\text{Exp}(\lambda)$ 随机变量。
- 条件分布：给定 $N_t = n$ （即在时间 t 内发生了 n 次到达），这 n 个到达的时间点在 $[0, t]$ 上是独立同分布且均匀分布的顺序统计量。即对于 $0 < s < t$ ，给定 $N_t = n$ ，在 $[0, s]$ 内到达的数量 k 服从二项分布 $\text{Bin}(n, \frac{s}{t})$

$$P(N_s = k \mid N_t = n) = \binom{n}{k} \left(\frac{s}{t}\right)^k \left(1 - \frac{s}{t}\right)^{n-k}$$

条件分布的推导过程：假设 $N_t = n$ ，要推导 $P(N_s = k \mid N_t = n)$ 的公式：

$$\begin{aligned} P(N_s = k \mid N_t = n) &= \frac{P(N_s = k \cap N_t = n)}{P(N_t = n)} \\ &= \frac{P(N_s = k)P(N_t - N_s = n - k)}{P(N_t = n)} \\ &= \frac{(\lambda s)^k e^{-\lambda s}}{k!} \cdot \frac{[\lambda(t-s)]^{n-k} e^{-\lambda(t-s)}}{(n-k)!} \cdot \frac{n!}{(\lambda t)^n e^{-\lambda t}} \\ &= \binom{n}{k} \left(\frac{s}{t}\right)^k \left(1 - \frac{s}{t}\right)^{n-k} \sim \text{Bin}\left(n, \frac{s}{t}\right) \end{aligned}$$

分布变换

线性变换法

如果 $U \sim \mathcal{U}(0, 1)$ ，生成任意区间 $[a, b]$ 的均匀分布： $X = a + (b - a)U$

逆变换法

原理：如果目标是分布 X ，其CDF是 $F(x)$ 。只要生成一个均匀分布 $U \sim \mathcal{U}(0, 1)$ ，然后令： $X = F^{-1}(U)$ ，那么 X 就会服从目标分布。

直观理解：CDF的纵坐标 $F(x)$ 的取值范围正好是 $[0, 1]$ 。如果你在纵轴上均匀地随机撒点（生成 U ），然后水平投射到CDF曲线上，再垂直投影到横轴，得到的 X 密度就会正好落在CDF陡峭的地方（概率密度大）。

经典例题：生成指数分布 $\text{Exp}(\lambda)$

步骤：

1. 求CDF: $F(x) = 1 - e^{-\lambda x}$
2. 令 $u = F(x)$, 即 $u = 1 - e^{-\lambda x}$ 。
3. 反解 x : $x = -\frac{1}{\lambda} \ln(1 - u)$

高斯分布

标准正态 $\mathcal{N}(0, 1)$: 生成 $U_1, U_2 \sim \mathcal{U}(0, 1)$: $Z = \sqrt{-2 \ln U_1} \cos(2\pi U_2)$

一般正态 $\mathcal{N}(\mu, \sigma^2)$: $X = \mu + \sigma Z$

多维随机变量

联合分布

离散型:

- 联合概率质量函数(Joint PMF): $p_{X,Y}(x, y) = P(X = x, Y = y)$
- 边缘PMF: $P_X(x) = \sum_y p_{X,Y}(x, y)$ (对固定 x , y 求和)

连续型:

- 联合概率密度函数(Joint PDF): $f_{X,Y}(x, y)$
- 性质: $f(x, y) \geq 0$, $\iint f(x, y) dx dy = 1$
- 概率计算: $P((X, Y) \in A) = \iint_A f(x, y) dx dy$
- 边缘PDF: $f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$ (对固定 x , y 积分)

独立性

定义: X 与 Y 独立 $\iff f_{X,Y}(x, y) = f_X(x)f_Y(y)$ (对所有的 x, y 成立)

判断技巧: 若联合PDF可以写成 $g(x)h(y)$, 且定义域是矩形区域, 则独立。

条件分布

离散型: $p_{Y|X}(y | x) = \frac{p_{X,Y}(x, y)}{p_X(x)}$

连续型: $f_{Y|X}(y | x) = \frac{f_{X,Y}(x, y)}{f_X(x)}$ 注意, 在计算时, 先计算边缘分布 $f_X(x)$, 再作为分母。

独立随机变量之和(卷积公式)

若 X, Y 独立, 令 $Z = X + Y$ 。

- 离散型 (和分布): $p_Z(z) = \sum_k p_X(k)p_Y(z - k)$
- 连续型 (卷积): $f_Z(z) = \int_{-\infty}^{\infty} f_X(x)f_Y(z - x)dx$ 技巧: 确定 x 的取值范围, 使得 $f_X(x) > 0$ 且 $f_Y(z - x) > 0$

原始分布 X, Y	参数	和的分布 $Z = X + Y$	Z 的参数	规律总结
高斯分布	$\mathcal{N}(\mu_1, \sigma_1^2), \mathcal{N}(\mu_2, \sigma_2^2)$	正态分布	$\mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$	均值相加, 方差相加
泊松分布	$\text{Poi}(\lambda_1), \text{Poi}(\lambda_2)$	泊松分布	$\text{Poi}(\lambda_1 + \lambda_2)$	强度参数直接相加
二项分布(p 相同)	$\text{Bin}(m, p), \text{Bin}(n, p)$	二项分布	$\text{Bin}(m + n, p)$	试验次数相加, 概率 p 不变
指数分布(λ 相同)	$\text{Exp}(\lambda)$	Erlang分布	$\text{Gamma}(2, \lambda)$	
几何分布(p 相同)	$\text{Geo}(p)$	负二项分布	$\text{NB}(2, p)$	成功次数变为2

随机变量函数的联合分布

若 $(X, Y) \rightarrow (U, V)$ 是一一对应变换, 反函数为 $x = g(u, v), y = h(u, v)$, 则

联合PDF: $f_{U,V}(u, v) = f_{X,Y}(g(u, v), h(u, v)) \cdot |J|$

Jacobian行列式: $J = \det \begin{vmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{vmatrix}$, 这里的偏导数是反函数对 u, v 求导, 千万别反了!

经典例题: 假设 X, Y 是独立且均服从 $\mathcal{U}(0, 1)$, 求 $Z = X + Y$ 的PDF。

利用卷积公式: $f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z - x) dx$ 。

分析非零区域:

- $f_X(x)$ 非零需要 $0 \leq x \leq 1$
- $f_Y(z - x)$ 非零需要 $0 \leq z - x \leq 1$, 即 $x \leq z \leq x + 1$

分段讨论:

- 当 $0 \leq z \leq 1$ 时, $0 \leq x \leq z$ 即可, 则 $f_Z(z) = \int_0^z 1 \cdot 1 dx = z$
- 当 $1 < z \leq 2$ 时, $z - 1 \leq x \leq 1$ 即可, 则 $f_Z(z) = \int_{z-1}^1 1 \cdot 1 dx = 2 - z$

数字特征

期望与方差

期望的线性性质 (无论是否独立都成立): $\mathbb{E}[aX + bY + c] = a\mathbb{E}[X] + b\mathbb{E}[Y] + c$

期望的乘积性质 (只有在各变量独立时成立): $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$

方差的性质: $\text{Var}(aX + b) = a^2 \text{Var}(X)$

方差的计算: $\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 \geq 0$

Jenson不等式

它描述了**函数的期望与期望的函数**之间的关系, 也就是 $\mathbb{E}[\phi(X)]$ 和 $\phi(\mathbb{E}[X])$ 之间的大小关系。

- 若 $\phi(x)$ 是**凸函数**, 即 $\phi''(x) > 0$, 则 $\mathbb{E}[\phi(X)] \geq \phi(\mathbb{E}[X])$, 直觉: 函数弯曲向上, 平均值处的函数偏小, 平均后的函数值偏大。
- 若 $\phi(x)$ 是**凹函数**, 即 $\phi''(x) < 0$, 则 $\mathbb{E}[\phi(X)] \leq \phi(\mathbb{E}[X])$, 直觉: 函数弯曲向下, 平均值

处的函数偏大，平均后的函数值偏小。

函数 $\phi(X)$	形状	Jenson不等式结果
x^2	凸	$\mathbb{E}[X^2] \geq (\mathbb{E}[X])^2$
e^x	凸	$\mathbb{E}[e^X] \geq e^{\mathbb{E}[X]}$
$\frac{1}{x}$	凸	$\mathbb{E}[\frac{1}{X}] \geq \frac{1}{\mathbb{E}[X]}$
$\ln(x)$	凹	$\mathbb{E}[\ln X] \leq \ln(\mathbb{E}[X])$
$\sqrt{x}$	凹	$\mathbb{E}[\sqrt{X}] \leq \sqrt{\mathbb{E}[X]}$

协方差

定义: $\text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)] = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$

性质:

- 对称性: $\text{Cov}(X, Y) = \text{Cov}(Y, X)$, $\text{Cov}(X, X) = \text{Var}(X)$
- 线性性质: $\text{Cov}(aX + b, cY + d) = ac \cdot \text{Cov}(X, Y)$
- 和的方差: $\text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y) \pm 2\text{Cov}(X, Y)$

只有当 $\text{Cov}(X, Y) = 0$ 时 (注, 这不代表两者独立, 但是独立一定代表 $\text{Cov} = 0$) , 才有 $\text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y)$

推广到 n 个 i.i.d. 变量: 若 $X_1, X_2, \dots, X_n$ 相互独立,

- 令 $S_n = \sum_{i=1}^N X_i$, 则: $\text{Var}(S_n) = n \cdot \text{Var}(X_1)$
- 令 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^N X_i$, 则: $\text{Var}(\bar{X}_n) = \frac{\text{Var}(X_1)}{n}$

相关系数

定义: $\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$

性质: $|\rho_{XY}| \leq 1$, 若 $|\rho_{XY}| = 1$, 则说明 Y 和 X 完全线性相关。

不相关 vs 独立: 独立 $\implies$ 不相关 ($\rho = 0$) , 反之不一定成立

WHY???

首先要明确, 不相关的数学定义是 $\text{Cov}(X, Y) = 0$, 协方差以及相关系数本质上是在衡量 X 和 Y 之间是否存在线性关系, 而独立性意味着 X 和 Y 毫无瓜葛。因此如果 X 和 Y 独立, 就说明他们不可能有线性关系, 也就不相关。但是 X 和 Y 不相关仅仅意味着他们没有直线关系, 可能有二次关系, 不能推断他们独立。

最经典的例子就是 $Y = X^2$, 假设 $X \sim \mathcal{U}(-1, 1)$, 则 X 和 Y 显然不独立, 但是通过计算协方差:

$$\mathbb{E}[XY] = \mathbb{E}[X \cdot X^2] = \mathbb{E}[X^3] = 0$$

$$\mathbb{E}[X] = 0$$

$$\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y] = 0$$

他们协方差为0, 不相关, 但是有严格的函数关系 $Y = X^2$, 即不独立。

对于联合高斯分布，不相关等价于独立：因为高斯分布的所有信息都包含在均值和方差（协方差矩阵）里。如果协方差为0，联合PDF刚好可以分解成边缘PDF的乘积。

极限定理与推断统计

极限定理

切比雪夫不等式：对于任意 $k > 0$ ， $P(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}$ 或 $P(|X - \mu| < k\sigma) \geq 1 - \frac{1}{k^2}$

大数定律(LLN)：当 $n \rightarrow \infty$ 时，样本均值依概率收敛于真实期望，即 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \rightarrow \mu$

中心极限定理(CLT)：无论总体分布如何（只要方差存在），当 n 足够大时，样本和（或均值）近似服从正态分布，即 $S_n = \sum_{i=1}^n X_i \approx \mathcal{N}(n\mu, n\sigma^2)$ ，并且 $\bar{X}_n \approx \mathcal{N}(\mu, \frac{\sigma^2}{n})$ 。

估计基础

随机样本： $X_1, \dots, X_n$ 是独立同分布的样本

估计量：用于估计参数 θ 的统计量，记为 $\hat{\theta}$ （例如 $\bar{X}$ 估计 μ ）。

均方误差(MSE)：衡量估计好坏的标准。

$$\text{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + [\text{Bias}(\hat{\theta})]^2$$

其中 $\text{Bias}(\hat{\theta}) = \mathbb{E}[\hat{\theta}] - \theta$ ，如果 $\text{Bias} = 0$ （无偏），则 $\text{MSE} = \text{Var}(\hat{\theta})$

无偏估计量： $\mathbb{E}[\hat{\theta}] = \theta$

参数估计方法

似然函数：是一个关于 θ 的函数，对于每一个可能的 θ ，它告诉我们：“如果 θ 取这个值，那产生我手上这组数据的几率有多大？”

最大似然估计（MLE）

找到参数 θ 使“当前样本发生的概率最大”。

步骤：

- 写出似然函数 $L(\theta) = \prod_{i=1}^n f(x_i; \theta)$
- 取对数 $\ln L(\theta)$ （变成加法，方便求导）
- 对 θ 求导并令其为0，解出 $\hat{\theta}_{\text{MLE}}$

最小MSE估计（MMSE）

写出MSE关于 $\hat{\theta}$ 的表达式，求导令其为0即可。

二元假设检验

模型：

- H_0 （零假设）：观测 X 服从 $f_0(x)$
- H_1 （备择假设）：观测 X 服从 $f_1(x)$

决策规则：根据观测值 x ，决定判决为 D_0 （选 H_0 ）或 D_1 （选 H_1 ）

似然比检验：比较 $f_1(x)$ 和 $f_0(x)$ 的大小。

- **最大似然(ML)**：不考虑先验概率。若 $f_1(x) > f_0(x)$ ，判 H_1
- **最大后验概率(MAP)**：考虑先验 $P(H_0)$ 和 $P(H_1)$ 。若 $\frac{f_1(x)}{f_0(x)} > \frac{P(H_0)}{P(H_1)}$ ，即 $P(H_1)f_1(x) > P(H_0)f_0(x)$ ，判 H_1 。

错误类型：

- **虚警**： $P(D_1 | H_0) = \int_{R_1} f_0(x)dx$ (没病判有病)
- **漏检**： $P(D_0 | H_1) = \int_{R_0} f_1(x)dx$ (有病判没病)